

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3092 – Deep Learning

Proyecto 2

Detección de patrones sospechosos en remesas mediante aprendizaje en dos etapas

Olivier Viau
Milton Polanco
Roberto Najera

Guatemala, septiembre de 2026

Resumen ejecutivo

Este proyecto desarrolla una prueba de concepto para priorizar cuentas receptoras cuyas secuencias de transacciones ameritan revisión en un proceso de prevención de lavado de dinero. Se utilizó el conjunto completo de PaySim, con 6,362,620 transacciones sintéticas, y se construyeron secuencias cronológicas por cuenta. El sistema tiene dos etapas. La Etapa A es un autoencoder recurrente entrenado únicamente con cuentas normales; su error de reconstrucción funciona como score de anomalía. La Etapa B reutiliza el encoder, añade atención temporal y clasifica las cuentas con etiquetas disponibles. La evaluación se hizo sobre cuentas completamente separadas entre entrenamiento, validación y prueba.

El experimento de ablación muestra que las tres variantes tienen resultados cercanos. El sistema completo obtuvo la mayor PR-AUC de prueba (0.5679) y fue seleccionado por su F1 de validación (0.5438), aunque la variante de transferencia sin score explícito alcanzó el mayor F1 de prueba (0.5646). Esto obliga a una conclusión prudente: el score de anomalía aporta una señal complementaria e interpretable, pero su mejora predictiva es marginal en PaySim. El modelo debe verse como una herramienta de priorización para analistas, no como una decisión automática ni como prueba de lavado de dinero.

1. Problema de negocio y contexto regulatorio

Las remesas son esenciales para la economía guatemalteca. El Banco de Guatemala reportó US\$21,510.2 millones en remesas familiares durante 2024 [1]. La combinación de alto volumen, operaciones repetidas y canales transfronterizos también crea una superficie que puede ser utilizada para fraccionar fondos, concentrarlos en cuentas intermediarias o retirarlos rápidamente. El reto operativo consiste en revisar una cantidad manejable de alertas sin ignorar patrones relevantes ni afectar innecesariamente a clientes legítimos.

La Ley Contra el Lavado de Dinero u Otros Activos, Decreto 67-2001, tiene por objeto prevenir, controlar, vigilar y sancionar el lavado de dinero, y establece obligaciones para las personas obligadas [2]. La Intendencia de Verificación Especial (IVE), dentro de la Superintendencia de Bancos, vela administrativamente por el cumplimiento del marco de prevención y analiza los reportes de transacción sospechosa remitidos por las entidades obligadas [3]. En el ámbito regional, GAFILAT evalúa tanto el cumplimiento técnico de las recomendaciones internacionales como la efectividad con que los países aplican sus controles [4]. Por ello, un modelo útil no debe limitarse a producir una etiqueta: debe documentar su origen, mostrar la evidencia transaccional y permitir que un analista cuestione el resultado.

La literatura reciente coincide en que la detección AML combina perfiles de riesgo del cliente con señales de comportamiento sospechoso [5]. También advierte que las relaciones entre cuentas y grupos pueden aportar información que un análisis aislado no observa [7, 6]. Nuestra prueba de concepto se concentra en comportamiento secuencial por cuenta receptora. Esa elección permite estudiar temporalidad y atención, pero no sustituye un análisis de red ni información de conocimiento del cliente (KYC).

2. Datos y decisiones de diseño

2.1. Unidad de análisis y construcción de secuencias

Aunque el enunciado propone secuencias por remitente, el análisis exploratorio mostró que 99.85 % de los identificadores `nameOrig` aparecen una sola vez; no existe historia suficiente para modelar su comportamiento. En cambio, `nameDest` acumula operaciones. Por ello se adoptó como unidad de análisis la cuenta receptora, decisión que favorece la detección de cuentas concentradoras. No se presenta como una equivalencia perfecta con una remesadora real: es una adaptación necesaria a la estructura observable de PaySim.

Se conservaron las transacciones dirigidas a cuentas y se formaron 571,961 secuencias. La ventana máxima se fijó en 24 operaciones, el percentil 95 de longitud, y para historiales mayores se conservaron las operaciones más recientes. El label se calculó después del truncamiento: una secuencia es positiva únicamente cuando contiene fraude visible dentro de la ventana. De esta forma, 7,968 cuentas quedaron positivas y se evitó etiquetar como sospechosa una ventana cuyo evento fraudulento ya había sido descartado. La Figura 1 resume longitudes y balance.




Figura 1: Distribución de longitudes y proporción de cuentas positivas. Fuente: elaboración propia con PaySim.

Cada paso contiene monto transformado con $\log_{1p}$, horas desde la operación anterior, cambio del monto logarítmico, desviación respecto al historial previo, hora codificada con seno y coseno, y tipo de transacción mediante embedding. Los balances del destino se excluyeron porque PaySim no los actualiza consistentemente. También se excluyeron los balances del origen: 97.50 % de las operaciones fraudulentas vacían exactamente el saldo de origen, una regla casi inexistente en la clase normal. Incluir monto y ambos balances produciría un atajo propio del simulador, con métricas altas pero poca posibilidad de transferencia a datos reales.

Las cuentas se dividieron de forma estratificada en 70 % entrenamiento, 15 % validación y 15 % prueba. Ninguna cuenta aparece en más de un conjunto. El escalador se ajustó únicamente con 2,943,166 transacciones de entrenamiento. La distribución natural se conservó en los tres conjuntos; el desbalance se trató mediante $\text{pos_weight}=70.78$ dentro de la pérdida binaria, sin combinarlo con sobremuestreo.

2.2. Conexión con los contenidos del curso

El diseño integra técnicas vistas en distintas semanas. La representación many-to-one mediante GRU corresponde al modelado recurrente de la Semana 3. El autoencoder que comprime y reconstruye una secuencia aplica la lógica encoder-decoder de la Semana 4. La ponderación de operaciones mediante atención temporal conecta con la Semana 5. La entropía cruzada binaria ponderada, Adam y el control de sobreajuste mediante validación y parada temprana retoman pérdida, regularización y optimización de la Semana 8. Finalmente, la reutilización del encoder, primero congelado y luego ajustado con una tasa de aprendizaje menor, aplica feature extraction y fine-tuning diferencial de la Semana 9.

3. Sistema de detección en dos etapas

3.1. Etapa A: aprendizaje de la normalidad

La Etapa A utiliza un embedding del tipo de operación, un encoder GRU y un decoder GRU que reconstruye las variables numéricas y el tipo de transacción. Se entrenó exclusivamente con 394,794 secuencias normales; la selección del checkpoint utilizó otras 84,599 secuencias normales de validación. El padding se colocó a la derecha y se excluyó de la pérdida mediante máscaras y longitudes reales.

El score combina el error cuadrático de las variables numéricas con la entropía cruzada del tipo. El umbral, 1.0452, se eligió en validación maximizando F1 sobre la curva precision-recall. En prueba, la Etapa A por sí sola alcanzó PR-AUC 0.0180, ROC-AUC 0.5761 y F1 0.0295. El resultado es bajo, pero informativo: una anomalía de reconstrucción no equivale automáticamente a fraude. El valor de esta etapa está en aprender una representación sin etiquetas y producir una señal de rareza que pueda combinarse con evidencia supervisada.

3.2. Etapa B: transferencia, atención y calibración

La Etapa B reutiliza el encoder de la Etapa A y agrega una cabeza de atención temporal. Los modelos transferidos se entrenaron primero con el encoder congelado y después con fine-tuning, usando una tasa diez veces menor para el encoder que para la cabeza nueva. La pérdida fue BCEWithLogitsLoss ponderada. Como esa ponderación altera la interpretación directa del sigmoid, las salidas se calibraron con Platt sobre validación. El umbral de cada variante se fijó en validación antes de evaluar prueba.

La atención entrega una distribución sobre las operaciones válidas. Un peso alto identifica la transacción que más influyó en la representación utilizada por la cabeza clasificadora; no demuestra causalidad ni sustituye una investigación. Esta distinción es coherente con trabajos recientes que incorporan explicabilidad a modelos AML para apoyar la revisión humana [8].

4. Experimento de ablación

Se compararon tres modelos con la misma división de datos: un baseline entrenado desde cero, transferencia del encoder sin score explícito y transferencia con el score de anomalía. La selección final se hizo por F1 de validación, no por el resultado de prueba. La Tabla 1 contiene las métricas obtenidas sobre 85,795 cuentas de prueba.

Cuadro 1: Comparación de variantes en el conjunto de prueba.

Variante	PR-AUC	ROC-AUC	Precisión	Recall	F1
Baseline desde cero	0.5662	0.9295	0.7057	0.4594	0.5565
Transferencia	0.5654	0.9277	0.7198	0.4644	0.5646
Transferencia + anomalía	0.5679	0.9298	0.7090	0.4669	0.5631




Figura 2: Curvas de precisión-recall y F1 de prueba de las variantes. Fuente: elaboración propia.

El sistema completo fue seleccionado porque obtuvo el mayor F1 de validación (0.5438 frente a 0.5365 y 0.5341) y la mayor PR-AUC en prueba. Sin embargo, la diferencia es pequeña y transferencia sin score logró el mejor F1 de prueba. Por tanto, la evidencia no permite afirmar que la arquitectura de dos etapas produzca una mejora amplia o estable en PaySim. Sí demuestra que la representación preentrenada puede reutilizarse sin degradar el desempeño y que el score de anomalía aporta una señal adicional auditable. El lift del 1 % fue similar: 47.78 para baseline, 48.20 para transferencia y 48.03 para el sistema completo. Operativamente, el ranking concentra muchos más positivos que una revisión aleatoria, pero el umbral debe ajustarse a la capacidad real del equipo de cumplimiento.

5. Interpretabilidad y análisis de casos

Se eligieron cinco cuentas de prueba: tres verdaderos positivos, un falso positivo y un falso negativo. En la Figura 3, los colores muestran el peso de atención y las estrellas identifican operaciones etiquetadas como fraude. La concentración extrema de atención facilita ubicar la operación relevante, aunque también muestra que el modelo suele apoyar casi toda su decisión en un solo paso.




Figura 3: Mapas de atención para tres aciertos y dos errores. Fuente: elaboración propia.

C977281429, verdadero positivo. La cuenta tiene 24 operaciones. La posición 14 es un retiro CASH_OUT de aproximadamente 8.75 millones y concentra 99.95 % de la atención. Su monto se separa claramente del historial. La probabilidad calibrada es 99.98 % y el score de anomalía 1.4456, superior al umbral de la Etapa A. Ambas etapas coinciden en priorizarla.

C978277137, verdadero positivo. En una secuencia de 21 operaciones, la última es un retiro de aproximadamente 3.19 millones después de 324 horas. Recibe 99.48 % de la atención. La probabilidad es 99.98 % y el score de anomalía 0.9523. Aunque el score no supera el umbral aislado de la Etapa A, la representación secuencial y la cabeza supervisada sí reconocen el patrón. El caso ilustra por qué no conviene usar la anomalía como única regla.

C1185406486, verdadero positivo. La primera de 12 operaciones es una transferencia de aproximadamente 4.45 millones y recibe 99.30 % de la atención. La probabilidad es 99.98 % y el score de anomalía 0.9559. La operación aparece al inicio, por lo que el mecanismo de atención evita que su señal se pierda al

resumir toda la secuencia.

C1307220530, falso positivo. La cuenta contiene 19 operaciones normales según PaySim. Un retiro de aproximadamente 1.89 millones concentra 99.01 % de la atención y eleva la probabilidad a 99.98 %, aunque el score de anomalía es 0.6513. El modelo confunde un monto legítimo atípico con un caso sospechoso. En producción, el analista necesitaría revisar actividad económica, origen de fondos y documentación antes de escalarlo.

C1641312686, falso negativo. La secuencia tiene cinco operaciones y termina con un retiro fraudulento de aproximadamente 414,973, separado por 153 horas. Esa operación concentra 99.76 % de la atención, pero la probabilidad es 26.01 %, ligeramente inferior al umbral final de 26.33 %; el score de anomalía es 0.2185. El modelo localizó la operación correcta, pero la intensidad de sus señales no alcanzó el punto de corte. Este caso muestra que atención correcta no garantiza clasificación correcta y que pequeñas variaciones del umbral cambian decisiones cercanas al límite.

6. Limitaciones y requisitos para producción

La principal limitación es la naturaleza sintética de PaySim. Sus etiquetas representan escenarios simulados de fraude y no cubren la variedad de tipologías, procesos de investigación ni cambios de comportamiento de una remesadora real. Los umbrales y la calibración no deben trasladarse directamente a producción. Además, el cambio de remitente a receptor fue necesario por la estructura del dataset, pero restringe la interpretación del sistema respecto del problema original.

El modelo analiza cada cuenta por separado. No conecta emisores, receptores, dispositivos, ubicaciones o beneficiarios compartidos. Los trabajos basados en grafos muestran que las relaciones y comportamientos coordinados pueden revelar estructuras que no aparecen en una secuencia individual [6, 7]. Una versión posterior debería combinar el historial temporal con una red transaccional.

También se requiere información KYC, ocupación, perfil esperado, país de origen y destino, listas PEP y sanciones, canal utilizado y resultados de investigaciones anteriores. Deben establecerse validación independiente, control de versiones, monitoreo de deriva, recalibración periódica y pruebas de sesgo. La salida debe ser una lista priorizada con evidencia; el oficial de cumplimiento conserva la decisión de investigar o reportar. Finalmente, el umbral debe definirse según costos y capacidad operativa, no solo maximizando F1. Un piloto apropiado ejecutaría el modelo en paralelo con los controles existentes, mediría alertas útiles por analista y documentaría falsos positivos y falsos negativos antes de cualquier automatización.

7. Conclusión

La prueba de concepto demuestra un pipeline reproducible que transforma millones de transacciones en secuencias, aprende normalidad sin etiquetas, transfiere esa representación a clasificación y señala las operaciones con mayor atención. El sistema completo alcanzó PR-AUC 0.5679, F1 0.5631 y lift cercano a 48 en el 1 % de mayor riesgo. La ablación muestra que la ventaja sobre el baseline es modesta, por lo que el principal aporte de la Etapa A es una señal complementaria e interpretable, no una mejora concluyente. El siguiente paso responsable es validar con datos reales, ampliar el contexto a relaciones entre cuentas y medir el efecto sobre el trabajo de analistas bajo supervisión humana.

Uso de IA generativa

Se utilizó IA generativa como apoyo técnico para ordenar el flujo del notebook, depurar errores de implementación y mejorar la claridad de algunas visualizaciones y explicaciones. Las decisiones sobre la unidad de análisis, variables, arquitectura, estrategia de entrenamiento, métricas y conclusiones fueron revisadas y validadas por el equipo.

Referencias

- [1] Banco de Guatemala. (2025). *Guatemala en cifras 2025*, sección de remesas familiares 2019–2024. https://pinfex.banguat.gob.gt/sites/default/files/banguat/Publica/guatemala_en_cifras_2025.pdf
- [2] Congreso de la República de Guatemala. (2001). *Decreto Número 67-2001, Ley Contra el Lavado de Dinero u Otros Activos*. Superintendencia de Bancos. https://www.sib.gob.gt/c/document_library/get_file?folderId=7450432&name=DLFE-36514.pdf
- [3] Superintendencia de Bancos de Guatemala. (2024). *Manual de organización y funciones: Intendencia de Verificación Especial*. https://www.sib.gob.gt/c/document_library/view_online_get_file?folderId=10217453&name=DLFE-41520.pdf
- [4] GAFILAT. (2016). *Informe de Evaluación Mutua de la República de Guatemala*. <https://biblioteca.gafilat.org/wp-content/uploads/2024/07/IEM-Guatemala-CuartaRonda.pdf>
- [5] Jensen, R. I. T., e Iosifidis, A. (2023). Fighting money laundering with statistics and machine learning. *IEEE Access*, 11, 8889–8903. <https://doi.org/10.1109/ACCESS.2023.3239549>
- [6] Dumitrescu, B., Baltoiu, A., y Budulan, S. (2022). Anomaly detection in graphs of bank transactions for anti money laundering applications. *IEEE Access*, 10, 47699–47714. <https://doi.org/10.1109/ACCESS.2022.3170467>
- [7] Cheng, D., Ye, Y., Xiang, S., Ma, Z., Zhang, Y., y Jiang, C. (2023). Anti-money laundering by group-aware deep graph learning. *IEEE Transactions on Knowledge and Data Engineering*, 35(12), 12444–12457. <https://doi.org/10.1109/TKDE.2023.3272396>
- [8] Kute, D. V., Pradhan, B., Shukla, N., y Alamri, A. (2024). Explainable deep learning model for predicting money laundering transactions. *International Journal on Smart Sensing and Intelligent Systems*, 17(1). <https://doi.org/10.2478/ijssis-2024-0027>