

UNIVERSIDAD DEL VALLE DE GUATEMALA

Deep Learning



Proyecto 2

Huffman Coding

Olivier Viau

Milton Polanco

GUATEMALA, 27 de septiembre del 2026

Resumen

Guatemala recibió US\$21,510 millones en remesas familiares durante 2024, cerca del 19.6% del PIB nacional y la segunda cifra más alta de América Latina, después de México. Ese volumen, sumado a la cantidad de transacciones que lo componen, hace que el segmento de remesas sea un punto de atención permanente para las autoridades de prevención de lavado de dinero, tanto a nivel nacional como regional.

Este reporte presenta los resultados de una prueba de concepto (POC) de un sistema de inteligencia artificial diseñado para analizar el comportamiento de las cuentas que reciben transferencias y priorizar, dentro de un alto volumen de operaciones, cuáles ameritan revisión por parte de un analista de cumplimiento. El sistema no reemplaza el criterio humano ni el proceso regulatorio existente: es una herramienta de priorización que se sumaría a los controles actuales.

El desarrollo se validó sobre un conjunto de datos de referencia de 6.36 millones de transacciones, con una estructura equivalente a un flujo real de operaciones de remesas (montos, tipos de operación, saldos antes y después de cada movimiento). El hallazgo más relevante es que un enfoque de dos etapas primero “enseñarle” al sistema qué es un comportamiento normal, y luego afinar esa base con los pocos casos de fraude confirmado disponibles mejoró de forma clara la capacidad de priorizar alertas frente al enfoque tradicional de entrenar un solo modelo desde cero. También encontramos, con la misma honestidad con la que reportamos lo positivo, que el beneficio no viene de la forma en que se combinaron los componentes, sino específicamente de exponer al sistema final el “grado de rareza” detectado en la primera etapa como un dato adicional de decisión.

Antes de considerar cualquier despliegue productivo, el sistema requiere: datos reales y no sintéticos, un proceso formal de validación y gobernanza de modelos, integración con los procesos de reporte a la Intendencia de Verificación Especial (IVE), y una capa de revisión humana. Estas condiciones se detallan en la sección de limitaciones.

1. El problema de negocio en el contexto regulatorio guatemalteco y centroamericano

1.1 Por qué las remesas son un punto de atención en materia de lavado de dinero

El alto volumen de remesas hacia Guatemala (US\$21,510 millones en 2024, con meses individuales que han superado los US\$2,000 millones) y su papel central en la economía familiar del país generan, junto con el beneficio económico evidente, una superficie de riesgo: un flujo de fondos de este tamaño, compuesto por millones de operaciones de montos relativamente bajos, es un canal atractivo para quienes buscan fraccionar, mezclar o dar apariencia de legitimidad a fondos de origen ilícito (“fraccionamiento” o smurfing, y el uso de cuentas intermediarias o “mula” que concentran depósitos de múltiples orígenes antes de retirarlos).

1.2 Marco legal vigente

- Decreto Número 67-2001 del Congreso de la República, Ley Contra el Lavado de Dinero u Otros Activos: tipifica el delito, establece penas de prisión incommutable de 6 a 20 años más multas equivalentes al valor de los bienes involucrados, y obliga a las entidades supervisadas a implementar controles internos, conocer a su cliente y reportar operaciones sospechosas e inusuales.

- Intendencia de Verificación Especial (IVE), adscrita a la Superintendencia de Bancos (SIB): es la autoridad encargada de recibir, analizar y dar seguimiento a los reportes de operaciones sospechosas de las entidades obligadas, incluidas las que operan en el negocio de remesas.
- GAFILAT (Grupo de Acción Financiera de Latinoamérica) y las 40 Recomendaciones del GAFI: Guatemala es miembro de GAFILAT y su marco normativo es evaluado periódicamente contra el estándar internacional. La Evaluación Mutua de 2016 identificó brechas que a la fecha de este reporte siguen en proceso de subsanarse: en 2026 se discute en el Congreso una reforma de 126 artículos, alineada con las 40 Recomendaciones y GAFILAT, que ampliaría el catálogo de sujetos obligados y endurecería las sanciones.
- Riesgo de “lista gris”: la Superintendencia de Bancos ha advertido públicamente que, de no aprobarse la actualización legal, Guatemala enfrenta el riesgo de mayor escrutinio internacional sobre sus operaciones financieras, lo que encarecería y ralentizaría las transacciones con el exterior un riesgo con impacto directo sobre el costo y la velocidad con que las remesas llegan al país.

En este contexto, un sistema que ayude a una entidad financiera o remesadora a priorizar mejor sus alertas de operaciones sospechosas no es solo una mejora operativa: contribuye directamente a la capacidad del país de demostrar, ante evaluadores de GAFILAT y ante el propio regulador (SIB/IVE), que sus controles de prevención son efectivos y no solo formales uno de los puntos centrales que el GAFI evalúa bajo su metodología de “efectividad”, más allá del cumplimiento normativo en el papel.

2. Decisiones de diseño del sistema

El sistema se diseñó explícitamente para ser explicable ante un equipo de cumplimiento y auditable ante un regulador, evitando decisiones de “caja negra” que no se puedan justificar. A continuación, las decisiones principales, con su justificación técnica y de negocio.

2.1 Analizar la cuenta que recibe, no solo la transacción individual

Un análisis inicial de los datos mostró que, en un flujo de remesas, casi cada remitente envía dinero una sola vez dentro de la ventana de datos disponible no hay un historial que construir de ese lado. En cambio, las cuentas que reciben transferencias sí acumulan un historial: varias operaciones a lo largo del tiempo, con montos y frecuencias propias de cada cuenta. Por eso el sistema construye un “perfil de comportamiento” por cuenta receptora, no por remitente que es también el enfoque más alineado con el objetivo de negocio: identificar cuentas concentradoras (potenciales “cuentas mula”), no remitentes individuales.

2.2 Excluir una señal que resultó ser un artefacto de los datos de prueba

Durante el desarrollo detectamos una variable que separaba casi perfectamente los casos de fraude de los normales en el conjunto de datos de referencia. Al investigar, encontramos que esa separación no reflejaba un patrón real de lavado de dinero, sino una particularidad de cómo se construyó el conjunto de datos sintético de prueba (los saldos de las cuentas receptoras no se actualizan de forma consistente para cierto tipo de operaciones legítimas). Decidimos excluir esa variable deliberadamente. La razón de negocio es directa: un sistema que aprende un atajo específico de los datos de prueba parecería excelente en el

laboratorio y fallaría al ponerse en producción con datos reales de un banco, donde ese atajo no existe. Preferimos un sistema más honesto, aunque eso implique un desempeño de prueba menos espectacular.

2.3 Un sistema de dos etapas: primero aprender lo normal, luego afinar con los casos confirmados

La primera etapa del sistema (“Etapa A”) aprende, a partir de miles de cuentas con comportamiento normal, cuál es el patrón típico de una cuenta receptora de remesas sin necesidad de que se le indique explícitamente cuáles son los casos de fraude. Aprende, en esencia, un “perfil de normalidad”. Cuando el sistema encuentra una cuenta que no se parece a lo que ha visto, esa dificultad para reconocerla como normal se convierte en un primer indicio de anomalía.

La segunda etapa (“Etapa B”) toma ese conocimiento ya adquirido y lo afina usando los casos de fraude que sí están confirmados y etiquetados que en la práctica de cualquier banco son relativamente pocos frente al volumen total de operaciones. Esta decisión responde directamente a una realidad del negocio: los casos de lavado de dinero confirmados y documentados son escasos y costosos de obtener (requieren investigación, a veces judicialización), mientras que el comportamiento “normal” es abundante. Diseñar un sistema que aprenda principalmente de lo abundante, y use lo escaso solo para el ajuste final, es una estrategia más realista que entrenar un modelo desde cero exigiéndole que aprenda todo únicamente de los pocos casos confirmados.

2.4 Balancear el entrenamiento sin distorsionar la medición del desempeño

Los casos de lavado de dinero son, por naturaleza, una fracción mínima del total de operaciones (en nuestros datos de referencia, 1.43% de las cuentas). Si se entrena un sistema sin ajustes, tiende a “ignorar” los casos raros porque acertar prediciendo siempre “normal” ya da un resultado aparentemente bueno. Para evitarlo, el sistema fue entrenado dándole más peso relativo a los casos de fraude durante el aprendizaje. Es importante aclarar que esto solo ocurre durante el entrenamiento: al medir qué tan bien funciona el sistema, se usa la proporción real y sin ajustes de casos normales y sospechosos, para que los resultados reportados en este documento reflejen honestamente lo que pasaría en la operación real.

2.5 Un punto de corte de decisión calculado, no arbitrario

El sistema no señala “sospechoso” o “normal” de forma binaria por diseño: produce un puntaje de riesgo. Convertir ese puntaje en una decisión (“alertar” o “no alertar”) requiere elegir un punto de corte, y ese punto de corte se calculó no se fijó arbitrariamente usando un conjunto de datos separado del que se usó para entrenar, buscando el equilibrio que generara la mejor proporción entre alertas correctas y alertas totales. Este mismo criterio se aplicó tanto al puntaje de “anomalía” de la primera etapa como a la decisión final del clasificador.

3. Resultados del experimento de comparación

Para verificar que el enfoque de dos etapas realmente aporta valor y no solo complejidad se comparó contra un modelo tradicional entrenado desde cero, y contra una variante intermedia, todas evaluadas sobre el mismo conjunto de prueba de 85,795 cuentas receptoras (1.42% de ellas con fraude confirmado), separado por completo de los datos usados en el entrenamiento.

Variante evaluada	Capacidad de distinguir un caso sospechoso de uno normal	Concentración de casos reales entre las alertas de mayor riesgo (vs. revisar al azar)
Modelo tradicional, entrenado desde cero (línea base)	64.8%	6.7 veces mejor que el azar
Solo reutilizar el conocimiento de la Etapa A (sin su señal de anomalía)	63.4%	5.0 veces mejor que el azar
Enfoque completo de dos etapas (conocimiento + señal explícita de anomalía)	77.2%	8.0 veces mejor que el azar

Tabla 1. “Capacidad de distinguir” responde: si el sistema recibe al azar un caso real de fraude y uno normal, ¿qué tan seguido identifica correctamente cuál es cuál? “Concentración” indica cuánto mejora la proporción de casos reales entre las alertas de mayor puntaje, frente a revisar cuentas sin ningún criterio. Datos calculados sobre el conjunto de prueba completo (85,795 cuentas).

3.1 Qué aporta cada etapa

El resultado más importante de este experimento no es solo que el enfoque de dos etapas gana (columna derecha de la Tabla 1): es entender por qué gana. La segunda fila muestra que reutilizar el conocimiento de la Etapa A sin explotar activamente su señal de anomalía no superó al modelo tradicional de hecho, quedó ligeramente por debajo. El salto real de desempeño (fila 3) ocurre únicamente cuando el sistema usa explícitamente el “grado de rareza” detectado por la Etapa A como un dato adicional para la decisión final, no solo como un punto de partida para el entrenamiento.

La implicación de negocio es concreta: el valor de “enseñarle primero al sistema qué es normal” no está en darle una ventaja inicial de entrenamiento, sino en producir una señal independiente y complementaria que tan rara es una cuenta respecto a todo lo que el sistema ha visto que se combina con el aprendizaje supervisado tradicional. Esto también simplifica la arquitectura recomendada para una siguiente fase: no es necesario reentrenar los pesos internos de la primera etapa dentro de la segunda; basta con calcular su puntaje de anomalía y usarlo como un insumo más.

4. Análisis de casos específicos

Los siguientes casos, tomados del conjunto de prueba usado durante el desarrollo, ilustran de forma concreta qué tipo de comportamiento el sistema reconoce, y dónde todavía tiene puntos ciegos. Los identificadores de cuenta se muestran tal como aparecen en el conjunto de datos de referencia (sintético); no corresponden a clientes reales.

4.1 Casos detectados correctamente

- Cuenta A: recibió un depósito de rutina (~Q31,900) y, horas más tarde, fue vaciada por completo mediante un solo retiro por el saldo exacto disponible. Este patrón de “vaciado inmediato de

cuenta” es una de las señales más claras de lavado de dinero, y el sistema lo identificó correctamente.

- Cuenta B: recibió una única transferencia que retiró el saldo total disponible en la cuenta de origen, sin ningún otro historial previo. El sistema la marcó correctamente como sospechosa incluso con un historial mínimo evidencia de que no depende únicamente de tener muchas transacciones previas para funcionar.

4.2 Casos no detectados (falsos negativos) límites actuales del sistema

- El “otro lado” de una misma operación: en varios casos de fraude, la operación real ocurre en dos pasos una transferencia que vacía una cuenta de origen, seguida casi de inmediato por un retiro en efectivo del mismo monto desde otra cuenta. El sistema, al perfilar cada cuenta receptora por separado, detectó el retiro (Cuenta A arriba) pero no la transferencia asociada, porque esta última llegó a una cuenta receptora sin ningún otro historial que diera contexto adicional. Esto muestra un límite de diseño: el sistema evalúa cuentas de forma individual y no conecta explícitamente ambas mitades de una misma operación de lavado.
- La “aguja en el pajar”: una cuenta con 18 transacciones (una actividad relativamente alta y variada) tenía una sola operación fraudulenta escondida entre montos y tipos de operación normales. El sistema no la marcó: al evaluar el comportamiento general de la cuenta, la gran cantidad de actividad legítima diluyó la señal de esa única operación sospechosa. Esto sugiere que, en una siguiente versión, convendría que el sistema pueda señalar transacciones puntuales dentro de una cuenta activa, y no solo calificar la cuenta como un todo.

4.3 Falsas alarmas

- Una cuenta recibió una transferencia con un monto moderado y, en una operación posterior no relacionada, su saldo bajó a cero pero sin que el monto de esa segunda operación coincidiera con un vaciado exacto de cuenta. El sistema generó una alerta por la similitud superficial con el patrón de vaciado de cuenta, aunque en este caso no hubo indicio real de fraude. Este tipo de caso es exactamente el que una capa de revisión humana debe filtrar antes de escalar una alerta a un Reporte de Operación Sospechosa formal ante la IVE.

5. Limitaciones del sistema y requisitos para producción

Este sistema es una prueba de concepto construida y validada con datos sintéticos de referencia. Antes de considerar cualquier uso en producción dentro de una empresa de remesas o un banco real, se requiere, como mínimo:

- Datos reales y representativos: entrenar y volver a validar el sistema con datos históricos reales de la propia institución (transacciones, cuentas, y casos confirmados y documentados de lavado de dinero), bajo un esquema de gobernanza de datos y protección de información personal.
- Calibración operativa del punto de corte: el umbral de decisión reportado en este documento se calculó sobre datos de referencia sintéticos. En producción debe recalibrarse considerando la capacidad real del equipo de cumplimiento para revisar alertas (cuántos casos puede investigar un analista por día) y el costo de cada tipo de error.

- Capa de revisión humana obligatoria: el sistema debe entregar una lista priorizada de casos para revisión, nunca generar un Reporte de Operación Sospechosa de forma automática. La decisión final de reportar a la IVE debe mantenerse en manos de un oficial de cumplimiento, conforme lo exige el Decreto 67-2001.
- Gobernanza y documentación del modelo: procesos formales de validación independiente, documentación de las decisiones de diseño (como las de este reporte) y capacidad de explicar cada alerta ante un auditor o evaluador de GAFILAT un sistema que no se puede explicar es, en la práctica, un riesgo de cumplimiento adicional, no una solución.
- Monitoreo y reentrenamiento continuo: quienes lavan dinero adaptan sus métodos; un sistema entrenado una sola vez pierde efectividad con el tiempo. Se requiere un proceso periódico de reentrenamiento y una auditoría independiente recurrente de su desempeño.
- Cobertura de tipologías adicionales: los datos de referencia usados en esta prueba solo contienen patrones de vaciado de cuentas. Un sistema de producción debe incorporarse a un conjunto más amplio de señales información de conocimiento del cliente (KYC), listas de personas expuestas políticamente (PEP), geografía de origen y destino que no están presentes en los datos transaccionales por sí solos.
- Pruebas de equidad: dado el peso social de las remesas para millones de familias guatemaltecas, es indispensable validar que el sistema no genere fricciones desproporcionadas sobre remitentes o receptores legítimos de bajos montos, que son la inmensa mayoría del volumen.

Conectar ambas mitades de una misma operación de lavado (ver sección 4.2) y permitir señalar transacciones puntuales dentro de una cuenta activa son las dos mejoras técnicas más importantes identificadas antes de una siguiente fase de desarrollo

6. Conclusión y recomendación

La prueba de concepto demuestra, con evidencia empírica y no solo con argumentos teóricos, que un enfoque de dos etapas puede mejorar de forma sustancial la priorización de alertas de posible lavado de dinero frente a un enfoque tradicional concentrando los casos reales de sospecha hasta 8 veces mejor que una revisión sin ningún criterio. Al mismo tiempo, el análisis de casos específicos deja claro que el sistema, en su estado actual, es un complemento a los controles existentes, no un reemplazo de ellos.

Recomendamos avanzar a una fase piloto controlada: reentrenar y validar el sistema con datos históricos reales de la institución (bajo los debidos acuerdos de confidencialidad y gobernanza de datos), definir junto con el equipo de cumplimiento el punto de corte operativo, y correr el sistema en paralelo a los controles actuales sin sustituirlos durante un período de observación antes de evaluar cualquier integración formal al proceso de reporte a la IVE.

Referencias

- Decreto numero 67-2001, Ley contra el lavado de dinero u otros activos. (2001, diciembre 17). vLex. <https://gt.vlex.com/vid/decreto-numero-67-2001-741400565>
- IVE. (s/f). Gob.gt. Recuperado el 11 de septiembre de 2026, de <https://www.sib.gob.gt/ive/>
- . sib.gob.gt/ive
- (S/f-b). Gafilat.org. Recuperado el 11 de septiembre de 2026, de <https://biblioteca.gafilat.org/wp-content/uploads/2024/07/IEM-Guatemala-CuartaRonda.pdf>
- Banguat. (s/f). Remesas familiares. Gob.gt. Recuperado el 11 de septiembre de 2026, de <https://banguat.gob.gt/page/remesas-familiares-0>
- (S/f-c). Researchgate.net. Recuperado el 11 de septiembre de 2026, de https://www.researchgate.net/publication/338726110_Detecting_money_launders_transactions_with_machine_learning
- Jensen, R. I. T., & Iosifidis, A. (2023). Fighting money laundering with statistics and machine learning. *IEEE Access*, 11, 8889-8903.
- Lo, W. W., Kulatilleke, G. K., Sarhan, M., Layeghy, S., & Portmann, M. (2022). Inspection-L: Self-supervised GNN node embeddings for money laundering detection in Bitcoin. En *arXiv [cs.CR]*. <https://doi.org/10.48550/arXiv.2203.10465>
- Cheng, D., Ye, Y., Xiang, S., Ma, Z., Zhang, Y., & Jiang, C. (2023). Anti-money laundering by group-aware deep graph learning. *IEEE Transactions on Knowledge and Data Engineering*, 35(12), 12444–12457. <https://doi.org/10.1109/tkde.2023.3272396>
- Kute, D. V., Pradhan, B., Shukla, N., & Alamri, A. (2024). Explainable deep learning model for predicting money laundering transactions. *International Journal on Smart Sensing and Intelligent Systems*, 17(1). <https://doi.org/10.2478/ijssis-2024-0027>
- Basaran-Brooks, B. (2022). Money laundering and financial stability: does adverse publicity matter? *Journal of Financial Regulation and Compliance*, 30(2), 196–214. <https://doi.org/10.1108/jfrc-09-2021-0075>
- ChatGPT para organización y re redacción del documento. Prompt: Revisa mi documento sobre un modelo de lavado de dinero, modifica aquello que consideres que usa palabras muy técnicas para una persona que no sabe nada de machine learning y dale un tono profesional.
- ChatGPT para creación de tablas y graficas. Prompt: Basandote en los resultados de mis notebooks agrega tablas o graficas que consideres relevantes al reporte, dándole formato APA y una descripción.